


Student Employability

PREPARED BY
IBRAHIMA KABA
YOUSRA BELGHAZI
ABDELLATIF MESSAOUDI
NOHAYLA BENBOUAZZA
AMADOU DIALLO

Supervisor:
Mr ANISS MOUMEN

Summary



01 Introduction

02 Project implementation
steps

03 demonstration of the
results of R scripts

04 Conclusion

Introduction

This study examines the factors influencing the professional integration of our students. Using survey data and inferential statistics on R software, we analyze key trends and test hypotheses. Our objective is to provide data-driven recommendations to enhance the employability of future graduates.



Project implementation steps

Problem Statement

Defining the core research questions.

Data Structure

Data Dictionary & Conceptual Data Model (CDM).

Data Collection

Survey (Questionnaire) & Video Interviews.


Hypotheses

Setting assumptions for statistical testing.

R Analys

Inferential statistics and final results.

demonstration of the results of R scripts



A	B	C	D	E	F	G
Horodateur	Score	Quel est votre âge ?	Quel est ton genre ?	Quelle est votre filière ?	Quel est votre niveau actuelle ?	Avez-vous effectué un stage
12/3/2025 20:56:07	0	21 Femme	GIND	1ère année	Non	
12/4/2025 7:19:31	0	20 Femme	GE	1ère année	Non	
12/4/2025 8:31:33	0 20ans	Femme	GI	1ère année	Non	
12/4/2025 9:13:00	0	20 Femme	GRST	1ère année	Non	
12/4/2025 9:19:54	0	20 Femme	GI	1ère année	Non	
12/4/2025 9:22:40	0	19 Homme	GI	1ère année	Non	
12/4/2025 9:27:23	0	21 Homme	GIND	1ère année	Non	
12/4/2025 9:57:58	0	20 Femme	GI	1ère année	Non	
12/4/2025 10:17:05	0	21 Homme	GI	1ère année	Oui	
12/4/2025 10:55:01	0	20 Femme	GIND	3ème année	Non	
12/4/2025 11:49:23	0	20 Femme	GI	1ère année	Non	
12/4/2025 13:28:28	0	21 Femme	GI	1ère année	Non	

PROJET (2).R* x

data x

Filter

	Horodateur	Score	Age	Genre	Filiere	Niveau	Stage	NbStages	DureeStage	ResultatsInfluence	item1
1	2025-12-03 20:40:29	0	22.0	Homme	GIND	1ère année	Non	0.0	0 mois	Non	D'accord
2	2025-12-03 20:56:06	0	21.0	Femme	GIND	1ère année	Non	0.0	0 mois	Non	Neutre
3	2025-12-04 08:31:33	0	20ans	Femme	GI	1ère année	Non	0.0	0 mois	Oui	D'accord
4	2025-12-04 09:19:54	0	20.0	Femme	GI	1ère année	Non	0.0	0 mois	Non	Pas d'acc
5	2025-12-04 09:22:39	0	19.0	Homme	GI	1ère année	Non	0.0	0 mois	Non	D'accord
6	2025-12-04 09:27:23	0	21.0	Homme	GIND	1ère année	Non	0.0	0 mois	Non	Neutre
7	2025-12-04 09:57:58	0	20.0	Femme	GI	1ère année	Non	0.0	plus d'un mois	Oui	Pas du to
8	2025-12-04 10:17:05	0	21.0	Homme	GI	1ère année	Oui	2.0	plus d'un mois	Non	Pas d'acc
9	2025-12-04 11:49:22	0	20.0	Femme	GI	1ère année	Non	0.0	0 mois	Non	Pas du to
10	2025-12-04 13:28:27	0	21.0	Femme	GI	1ère année	Non	0.0	0 mois	Oui	Neutre
11	2025-12-04 14:29:44	0	19.0	Femme	GI	1ère année	Non	0.0	0 mois	Oui	Pas d'acc
12	2025-12-04 15:57:06	0	21.0	Homme	GI	1ère année	Oui	2.0	plus d'un mois	Non	Neutre
13	2025-12-04 17:53:26	0	20.0	Femme	GIND	1ère année	Non	0.0	0 mois	Non	D'accord
14	2025-12-04 19:34:07	0	21.0	Femme	GIND	2ème année	Oui	1.0	plus d'un mois	Oui	Tout a fa
15	2025-12-05 11:47:33	0	20.0	Femme	GIND	1ère année	Non	0.0	0 mois	Oui	Pas d'acc
16	2025-12-05 20:55:42	0	20.0	Homme	GIND	1ère année	Non	0.0	0 mois	Non	Tout a fa
17	2025-12-05 20:55:43	0	20.0	Homme	GIND	1ère année	Non	0.0	0 mois	Non	D'accord
18	2025-12-05 20:56:39	0	21.0	Femme	GIND	2ème année	Oui	1.0	Plus d'un mois	Non	D'accord
19	2025-12-05 20:58:24	0	21.0	Femme	GIND	1ère année	Oui	2.0	Un mois	Non	D'accord

```
#ETAPE1:FORMULATION DE LA PROBLEMATIQUE
# Il s'agit d'une etude statistique sur l'employabilite des etudiants.
#Problematique :Quels sont les facteurs académiques, professionnels et personnels
#qui influencent significativement l'employabilité des étudiants d'une école
# ,mesurée par l'obtention d'un emploi dans les six mois suivant l'obtention du diplôme ?

#ETAPE2:COLLECTE DE DONNEES
# Nous exportons nos donnees depuis le fichier excel "Questionnaire (réponses).xlsx"
library(readxl)
data <- read_excel("C:/Users/PC/Downloads/Questionnaire (réponses).xlsx")
View(data)

# Filtrage :Nous ciblons les etudiants des filieres GI et GIND en 1ère et 2ème année
data<- data[(data$Filiere %in% c("GIND", "GI")) & (data$Niveau %in% c("1ère année", "2ème année")), ]
# Nous renommons les colonnes pour plus de clarté
colnames(data) <- c("Horodateur", "Score", "Age", "Genre", "Filiere", "Niveau",
                    "Stage", "NbStages", "DureeStage", "ResultatsInfluence", "item1",
                    "item2", "item3", "item4",
                    "item5", "item6", "AutoFormation", "ContratPrefere")
```



```
#ETAPE3:PRETRAITEMENT
#3.1:Conversion et Codification
#3.1.1. Conversion des donnees
if(!is.character(data$Genre)){
  data$Genre=as.character(data$Genre)
}
data$Genre=as.factor(data$Genre)
if(!is.character(data$DureeStage)){
  data$DureeStage=as.character(data$DureeStage)
}
data$DureeStage=as.factor(data$DureeStage)
if(!is.character(data$Filiere)){
  data$Filiere=as.character(data$Filiere)
}
data$Filiere=as.factor(data$Filiere)
if(!is.character(data$Niveau)){
  data$Niveau=as.character(data$Niveau)
}
data$Niveau=as.factor(data$Niveau)
if(!is.character(data$Stage)){
  data$Stage=as.character(data$Stage)
}
data$Stage=as.factor(data$Stage)
if(!is.character(data$ResultatsInfluence)){
  data$ResultatsInfluence=as.character(data$ResultatsInfluence)
}
data$ResultatsInfluence=as.factor(data$ResultatsInfluence)
if(!is.character(data$item1)){
  data$item1=as.character(data$item1)
}
```

```
data$item1=as.factor(data$item1)
if(!is.character(data$item2)){
  data$item2=as.character(data$item2)
}
data$item2=as.factor(data$item2)
if(!is.character(data$item3)){
  data$item3=as.character(data$item3)
}
data$item3=as.factor(data$item3)
if(!is.character(data$item4)){
  data$item4=as.character(data$item4)
}
data$item4=as.factor(data$item4)
if(!is.character(data$item5)){
  data$item5=as.character(data$item5)
}
data$item5=as.factor(data$item5)
if(!is.character(data$item6)){
  data$item6=as.character(data$item6)
}
data$item6=as.factor(data$item6)
if(!is.character(data$AutoFormation)){
  data$AutoFormation=as.character(data$AutoFormation)
}
data$AutoFormation=as.factor(data$AutoFormation)
if(!is.character(data$Autofor)){
  data$ContratPrefere=as.character(data$ContratPrefere)
}
data$ContratPrefere=as.factor(data$ContratPrefere)
```

```
if(!is.numeric(data$Age)){
  data$Age=as.numeric(data$Age)
}
if(!is.numeric(data$Score)){
  data$Score=as.numeric(data$Score)
}
if(!is.numeric(data$NbStages)){
  data$NbStages=as.numeric(data$NbStages)
}

#3.1.2. codification
recode <- c("Pas du tout d'accord" = 1,"Pas d'accord" = 2,"Neutre"=3,
           "D'accord" = 4,"Tout a fait d'accord" = 5)
data$item1 <- recode[data$item1]
data$item2 <- recode[data$item2]
data$item3 <- recode[data$item3]
data$item4 <- recode[data$item4]
data$item5 <- recode[data$item5]
data$item6 <- recode[data$item6]
```

Message d'avis :
 NAs introduits lors de la conversion automatique


21	2025-12-05 21:03:02	0	NA	Femme	GIND
22	2025-12-06 00:32:52	0	19	Homme	GIND

57	2026-01-10 21:10:25	0	72	Homme	GI	2ème année
58	2026-01-10 21:10:43	0	NA	Homme	GI	2ème année

#3.2: Nettoyage des donnees

#3.2.1. Traitement des valeurs abérantes

```
boxplot(data$Age)
boxplot.stats(data$Age)
for (i in 1:length(data$Age)){
  for (j in 1:length(boxplot.stats(data$Age)$out)){
    if (data$Age[i]==boxplot.stats(data$Age)$out[j] & !is.na(data$Age[i])){
      data$Age[i]=NA
    }
  }
}
boxplot(data$NbStages)
boxplot.stats(data$NbStages)
for (i in 1:length(data$NbStages)){
  for (j in 1:length(boxplot.stats(data$NbStages)$out)){
    if (data$NbStages[i]==boxplot.stats(data$NbStages)$out[j] & !is.na(data$NbStages[i])){
      data$NbStages[i]=NA
    }
  }
}
```



```
> boxplot.stats(data$NbStages)
$stats
[1] 0 0 0 1 2

$n
[1] 58

$conf
[1] -0.2074642  0.2074642


$out
numeric(0)
```

```
> boxplot.stats(data$Age)
$stats
[1] 19 20 20 21 22

$n
[1] 55

$conf
[1] 19.78695 20.21305

$out
[1] 22000378      109      72
```



#3.2.2. Traitement des valeurs manquantes

```
p=0
for (i in 1:length(data$Age)){
  if (is.na(data$Age[i])){
    p=p+1
  }
}
prop=(p/length(data$Age))*100
print(prop)
if (prop>5){
  for (i in 1:length(data$Age)){
    if (is.na(data$Age[i])){
      data$Age[i]=mean(data$Age,na.rm=TRUE)
    }
  }
}
data$Age=as.integer(data$Age)
p=0
for (i in 1:length(data$NbStages)){
  if (is.na(data$NbStages[i])){
    p=p+1
  }
}
prop=(p/length(data$NbStages))*100
print(prop)
if (prop>5){
  for (i in 1:length(data$NbStages)){
    if (is.na(data$NbStages[i])){
      data$NbStages[i]=mean(data$NbStages,na.rm=TRUE)
```

```
    }
  }
}
data$NbStages=as.integer(data$NbStages)
```

#3.3 Test de normalite

```
vars_num <- data[, c("Age","NbStages","item1","item2","item3",
                    "item4","item5","item6")]
# On teste tous les items en une seule fois en les regroupant dans une dataframe
normalite <- data.frame(
  Variable = colnames(vars_num),
  Skewness = sapply(vars_num, skewness, na.rm = TRUE),
  Kurtosis = sapply(vars_num, kurtosis, na.rm = TRUE),
  Shapiro_p = sapply(vars_num, function(x) shapiro.test(x)$p.value))
# Affichage de la data frame
normalite
# Ajout des critères du cours
normalite$Decision_Shapiro <- ifelse(normalite$Shapiro_p < 0.05, "H1 acceptee", "H0 rejetee")
# Critère de tolérance [-3, 3] pour Skewness et Kurtosis
normalite$Acceptable_Indicateurs <- ifelse(
  abs(normalite$Skewness) <= 3 & abs(normalite$Kurtosis) <= 3, "Toléré", "Trop biaisé")
for(i in 1:nrow(normalite)) {
  if(normalite$Shapiro_p[i] < 0.05) {
    cat("-", normalite$Variable[i], ": Le test de Shapiro rejette la normalité (p < 5%).")
    if(normalite$Acceptable_Indicateurs[i] == "Toléré") {
      cat(" Cependant, avec un Skewness et Kurtosis entre [-3,3], la distribution est acceptable p")
    } else {
      cat(" La distribution est trop asymétrique, on opte pour des tests non parametriques.\n")
    }
  } else {
    cat("-", normalite$Variable[i], ": La distribution est parfaitement normale (p > 5%).\n")
  }
}
```

> normalite

	Variable	Skewness	Kurtosis	Shapiro_p
Age	Age	0.2809458	2.941356	6.252520e-07
NbStages	NbStages	1.1341769	3.007733	4.900388e-10
item1	item1	0.2180943	1.958038	4.876961e-05
item2	item2	-0.2492612	1.222509	3.744741e-09
item3	item3	0.3297758	1.432512	9.732798e-08
item4	item4	0.2636284	3.127086	5.945871e-05
item5	item5	-0.3241259	1.310446	8.759574e-09
item6	item6	-0.6475837	1.568822	5.356050e-10

- Age : Le test de Shapiro rejette la normalité ($p < 5\%$). Cependant, avec un Skewness et Kurtosis entre $[-3,3]$, la distribution est acceptable pour des tests paramétriques.
- NbStages : Le test de Shapiro rejette la normalité ($p < 5\%$). La distribution est trop asymétrique, on opte pour des tests non paramétriques.
- item1 : Le test de Shapiro rejette la normalité ($p < 5\%$). Cependant, avec un Skewness et Kurtosis entre $[-3,3]$, la distribution est acceptable pour des tests paramétriques.
- item2 : Le test de Shapiro rejette la normalité ($p < 5\%$). Cependant, avec un Skewness et Kurtosis entre $[-3,3]$, la distribution est acceptable pour des tests paramétriques.
- item3 : Le test de Shapiro rejette la normalité ($p < 5\%$). Cependant, avec un Skewness et Kurtosis entre $[-3,3]$, la distribution est acceptable pour des tests paramétriques.
- item4 : Le test de Shapiro rejette la normalité ($p < 5\%$). La distribution est trop asymétrique, on opte pour des tests non paramétriques.
- item5 : Le test de Shapiro rejette la normalité ($p < 5\%$). Cependant, avec un Skewness et Kurtosis entre $[-3,3]$, la distribution est acceptable pour des tests paramétriques.
- item6 : Le test de Shapiro rejette la normalité ($p < 5\%$). Cependant, avec un Skewness et Kurtosis entre $[-3,3]$, la distribution est acceptable pour des tests paramétriques.

#3.4. Test de fiabilité et de validité

```
install.packages("psych")
library(psych)
#On regroupe les items
df_items <- data[, c("item1", "item2", "item3", "item4", "item5", "item6")]
```

Définition de la fonction pour le calcul de la fiabilité

```
Reliability <- function(tableau_items) {
  # Calcul de l'Alpha de Cronbach via le package psych
  res <- psych::alpha(tableau_items, check.keys = TRUE)
  alpha_val <- res$total$raw_alpha
  cat("Resultat de la fiabilite\n")
  cat("Alpha de Cronbach :", round(alpha_val, 3), "\n")
  if (alpha_val >= 0.7) {
    cat("Conclusion : Le questionnaire est fiable.\n")
  } else {
    cat("Conclusion : Le questionnaire est peu fiable.\n")
  }
  return(res)
}
```

#Resultat de la fiabilite

```
resultat_fiabilite <- Reliability(df_items)
```

```
> resultat_fiabilite <- Reliability(df_items)
Resultat de la fiabilite
Alpha de Cronbach : 0.477
Conclusion : Le questionnaire est peu fiable.
```

#3.5. Test de représentativité

```
table(data$Filiere)
(table(data$Filiere)/58)*100

# Test de Khi-2
test_rep <- chisq.test(table(data$Filiere), p=c(0.4915254237,0.5084745763))
if(test_rep$p.value > 0.05) {
  cat("Conclusion : L'échantillon est représentatif de la population réelle.\n")
} else {
  cat("Conclusion : L'échantillon n'est pas parfaitement représentatif.\n")
}
```

```
> table(data$Filiere)

GI GIND
25  33
> (table(data$Filiere)/58)*100

      GI      GIND
43.10345 56.89655
```

Conclusion : L'échantillon est représentatif de la population réelle.

#3.6. Test de saturation sémantique

Création de la dataframe

```
data_employabilite <- data.frame(  
  Themes = c( "Théorie vs Pratique", "Logiciels spécifiques", "Fondamentaux",  
              "Auto-formation", "Communication", "Travail en équipe",  
              "Adaptabilité", "Gestion du temps/stress", "Honnêteté/Confiance",  
              "Leadership", "Stages obligatoires", "Projets en équipe",  
              "Vie associative", "Projets personnels", "Manque de réseau",  
              "Manque d'expérience", "Marché saturé", "Étudiants étrangers",  
              "Mobilité", "Réseautage Alumni", "Partenariats entreprises",  
              "Ateliers CV/LinkedIn", "Module Insertion Prof.", "Alternance",  
              "Système Mentorat", "Portfolio/GitHub obligatoire",  
              "Crédibilité forums", "Sous-estimation par profs"),  
  Int_AD = c(1,0,0,1,1,1,1,0,0,0,1,1,1,0,1,1,1,0,1,0,1,1,0,0,0,0,0),  
  Int_IK = c(1,1,1,1,1,1,1,0,1,1,1,1,1,0,1,1,0,0,0,1,1,0,1,0,0,0,0),  
  Int_YB = c(1,1,0,1,1,1,0,0,1,0,1,1,1,0,1,0,1,0,1,1,1,0,0,0,0,1,0),  
  Int_NB = c(1,1,1,1,1,1,0,1,1,1,1,1,1,0,1,1,1,0,0,0,1,1,1,0,0,0,1,0),  
  Int_AM = c(1,1,1,1,1,1,1,0,0,1,1,0,1,0,1,0,0,0,1,0,1,1,0,1,1,0,1))  
  
# Calcul des occurrences par thème (Redondance)  
data_employabilite$Row_Sum <- rowSums(data_employabilite[, 2:6])  
  
# Total des occurrences redondantes (Thèmes cités au moins 2 fois)  
redondance_totale <- sum(data_employabilite$Row_Sum[data_employabilite$Row_Sum >= 2])  
  
# Total global des thèmes abordés (Toutes les occurrences, y compris les uniques)  
total_global <- sum(data_employabilite$Row_Sum)  
# Calcul du ratio  
saturation <- (redondance_totale / total_global) * 100
```

#Affichage des résultats

```
cat("Somme des thèmes redondants :", redondance_totale, "\n")  
cat("Total global des occurrences :", total_global, "\n")  
cat("Calcul de la saturation :", round(saturation, 2), "%\n")
```

#Conclusion

```
if(saturation >= 80) {  
  print("Conclusion : Niveau de saturation excellent. L'échantillon est validé.")  
} else {  
  print("Le niveau de saturation est faible.")  
}
```

> #Affichage des résultats

```
> cat("Somme des thèmes redondants :", redondance_totale, "\n")  
Somme des thèmes redondants : 79  
> cat("Total global des occurrences :", total_global, "\n")  
Total global des occurrences : 85  
> cat("Calcul de la saturation :", round(saturation, 2), "%\n")  
Calcul de la saturation : 92.94 %
```







[1] "Conclusion : Niveau de saturation excellent. L'échantillon est validé."

```
#ETAPE 4:TRAITEMENT
#4.1. Statistique descriptive
#4.1.1. Traitement numérique
summary(data)

#4.1.2. Traitement Graphique
install.packages("ggplot2")
library(ggplot2)
items <- paste0("item", 1:6)


for (it in items) {
  p <- ggplot(data, aes(x = .data[[it]])) +
    geom_histogram(aes(y = ..density..), bins = 10, fill="skyblue", color="black") +
    geom_density(color="red", size=1) +
    labs(title = paste("Distribution de l'", it), x = it, y = "Densité") +
    theme_minimal()

  print(p)
}
```




```
# Analyse de la sommabilité des items avec l'Analyse à Composantes Principales (ACP)
# Installation des packages
install.packages("FactoMineR")
install.packages("factoextra")

library(FactoMineR)
library(factoextra)
# On fait l'ACP sur les 6 items
res_acp <- PCA(data[, c("item1", "item2", "item3", "item4", "item5", "item6")], graph = FALSE)
# On affiche le cercle
fviz_pca_var(res_acp, col.var = "blue") +
  ggtitle("Toutes les flèches à droite = Somme possible")
```



```
# 4.2 Statistiques bivariées
# Test des hypothèses
chisq.test(table(data$item1))
chisq.test(table(data$item2))
chisq.test(table(data$item3))
chisq.test(table(data$item4))
chisq.test(table(data$item5))
chisq.test(table(data$item6))
```

```
data: table(data$item5)
X-squared = 39.586, df = 4, p-value = 5.271e-08
```

```
> chisq.test(table(data$item6))
```

Chi-squared test for given probabilities

```
data: table(data$item6)
X-squared = 67.517, df = 4, p-value = 7.584e-14
```

```
#4.2 : test des hypothèses
> chisq.test(table(data$item1))

Chi-squared test for given probabilities
data: table(data$item1)
X-squared = 10.448, df = 4, p-value = 0.03352

> chisq.test(table(data$item2))

Chi-squared test for given probabilities
data: table(data$item2)
X-squared = 47.345, df = 4, p-value = 1.292e-09

> chisq.test(table(data$item3))

Chi-squared test for given probabilities
data: table(data$item3)
X-squared = 20.621, df = 4, p-value = 0.0003765

> chisq.test(table(data$item4))

Chi-squared test for given probabilities
data: table(data$item4)
X-squared = 33.724, df = 4, p-value = 8.488e-07

> chisq.test(table(data$item5))

Chi-squared test for given probabilities
```

```

# Test parametrique et non parametrique
# Pour les items "Acceptables" (Paramétriques : 1, 2, 3, 5, 6)
# On compare les moyennes selon la filiere
items_param <- c("item1", "item2", "item3", "item5", "item6")

for (it in items_param) {
  # Utilisation de l'ANOVA car distribution suit un loi quasi normale
  res_anova <- aov(data[[it]] ~ data$Filiere, data =data)
  p_val <- summary(res_anova)[[1]][["Pr(>F)"]][1]

  cat("Item:", it, " p-value (ANOVA):", round(p_val, 4), "\n")
}

# Pour l'item 4
items_non_param <- c("item4")

# Utilisation de Kruskal-Wallis pour le test non parametrique
for (it in items_non_param) {
  res_kw <- kruskal.test(data[[it]] ~ data$Filiere)


  cat("Variable:", it, " p-value (Kruskal):", round(res_kw$p.value, 4), "\n")
}

```

```

Item: item1  p-value (ANOVA): 0.5089
Item: item2  p-value (ANOVA): 0.9472
Item: item3  p-value (ANOVA): 0.4483
Item: item5  p-value (ANOVA): 0.0598
Item: item6  p-value (ANOVA): 0.2552
> # Pour l'item 4
> items_non_param <- c("item4")
>
> # Utilisation de Kruskal-Wallis pour le test non parametrique
> for (it in items_non_param) {
+   res_kw <- kruskal.test(data[[it]] ~ data$Filiere)
+
+   cat("Variable:", it, " p-value (Kruskal):", round(res_kw$p.value, 4), "\n")
+ }
Variable: item4  p-value (Kruskal): 0.1839

```



**Thank you for
your attention**

